



Московский институт электроники и  
математики им. А.Н. Тихонова

Кафедра информационной  
безопасности киберфизических  
систем

Москва 2024

# Основы криптографии и стеганографии


Стегоанализ цифровых изображений



## Общие сведения о стегоанализе




## Задача стегоанализа







## Битовые плоскости цифрового изображения



## Битовые плоскости изображения после LSB-встраивания




## Битовые плоскости изображения после LSB-встраивания








## ДКП-спектр JPEG-изображения




## ДКП-спектр JPEG-изображения после встраивания





## Развитие методов стегоанализа






## Простейшие статистические методы


## Анализ пар значений

- Для LSB-встраивания.
- Подходит для случаев, когда сообщение встраивается последовательно или в подавляющее большинство пикселей.
- Идея анализа состоит в том, что после встраивания частоты соседних значений на гистограмме **выравниваются**.

Гистограмма до  
LSB-встраивания:




Гистограмма после  
LSB-встраивания:




## Анализ пар значений

1. Соседние значения, отличающиеся в последнем бите, формируют пары.
2. Ожидаемая частота после LSB-встраивания вычисляется как половина от количества пикселей со значениями из пары в изображении. Количество пикселей, попадающее в конкретную пару, не зависит от изменений в LSB.
3. Действительная частота цвета вычисляется из изображения.
4. Проверяется гипотеза равенства ожидаемой и действительной частоты с помощью критерия хи-квадрат.

Результат  
статистического  
анализа для  
изображения без  
встроенного  
сообщения:



Результат  
статистического  
анализа для  
изображения,  
заполненного  
наполовину:





## Статистические методы с выбором признаков



## Стегоанализ как задача классификации



- Стегоанализ цифровых изображений – задача **двухклассовой классификации**.
- Общая схема работы статистических методов стегоанализа с выбором признаков:
  1. Построение признакового пространства.
  2. Формирование обучающей выборки.
  3. Обучение классификатора.
- В качестве признаков используются различные статистические характеристики, рассчитываемые для элементов данных цифровых изображений в пространственной и частотной области.
- **JPEG-стегоанализ** является наиболее развитым направлением стегоанализа, так как JPEG – самый популярный формат представления цифровых изображений в сети Интернет.

## Набор признаков для выявления стегоизображений

- Известный классический набор признаков для JPEG-стегоанализа включает 23 признака, рассчитываемых как функционалы

$$X = \|f(J_1) - f(J_2)\|_{L_1},$$

где  $f(J_1)$  – некоторая векторная величина, рассчитанная для исследуемого изображения, а  $f(J_2)$  – аналогичная величина, рассчитанная для изображения, полученного из исходного изображения посредством его обрезания на 4 пикселя сверху и слева.



Fridrich J. Feature-Based Steganalysis for JPEG Images and its Implications for Future Design of Steganographic Schemes // Lecture Notes in Computer Science. – 2004. – Vol. 3200. – P. 67–81.

## Набор признаков для выявления стегоизображений

- Общая гистограмма квантованных ДКП-коэффициентов сжатого JPEG-изображения.
- Гистограммы первых пяти АС-коэффициентов.
- Одиннадцать двойных гистограмм АС-коэффициентов, принимающих значения из множества  $\{-5, 5\}$ .
- Пространственные межблочные зависимости в разных направлениях.

|    |    |    |    |    |    |    |    |
|----|----|----|----|----|----|----|----|
| 0  | 2  | 3  | 9  | 10 | 20 | 21 | 35 |
| 1  | 4  | 8  | 11 | 19 | 22 | 34 | 36 |
| 5  | 7  | 12 | 18 | 23 | 33 | 37 | 48 |
| 6  | 13 | 17 | 24 | 32 | 38 | 47 | 49 |
| 14 | 16 | 25 | 31 | 39 | 46 | 50 | 57 |
| 15 | 26 | 30 | 40 | 45 | 51 | 56 | 58 |
| 27 | 29 | 41 | 44 | 52 | 55 | 59 | 62 |
| 28 | 42 | 43 | 53 | 54 | 60 | 61 | 63 |

LF coefficients
  MF coefficients
  HF coefficients



## Методы классификации

- Метод ближайших соседей
- Наивный байесовский классификатор
- Линейный дискриминант Фишера
- Логистическая регрессия
- Машина опорных векторов
- Решающий лес

## Метод $k$ -ближайших соседей

- Отличается высокой точностью классификации, если векторы значений признаков, соответствующие объектам одного класса, компактно расположены в пространстве.
- Для проведения стегоанализа, необходимо сформировать выборку, состоящую из «чистых» изображений и стегоизображений. Для каждого изображения необходимо вычислить вектор значений выбранных признаков и запомнить полученные наборы векторов для каждого класса.
- Необходимо вычислить вектор значений выбранных признаков  $(x_1, x_2, \dots, x_l)$  для данного изображения и рассчитать расстояние между вычисленным вектором и всеми полученными ранее векторами.
- Векторы необходимо упорядочить по возрастанию расстояния и взять  $k$  наименьших расстояний (ближайших соседей). Исследуемое изображение относится к тому классу, представители которого преобладают среди найденных ближайших соседей.

## Наивный классификатор Байеса: основы

- **Теорема Байеса** определяет вероятность некоторого события при условии, что произошло другое взаимосвязанное с ним событие. Зная, с какой вероятностью причина приводит к некоему событию, эта теорема позволяет рассчитать вероятность того, что именно эта причина привела к наблюдаемому событию.
- Формула Байеса

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)},$$

где  $P(A)$  – вероятность гипотезы  $A$ ;

$P(A|B)$  – вероятность гипотезы  $A$  при наступлении события  $B$ ;

$P(B|A)$  – вероятность события  $B$  при истинности гипотезы  $A$ ;

$P(B)$  – полная вероятность наступления события  $B$ .

## Наивный классификатор Байеса: стегоанализ

- Задача стегоанализа:
  - $A_1$  – изображение является чистым;
  - $A_2$  – изображение является стегоизображением;
  - $x_1, x_2, \dots, x_k$  – набор признаков, характеризующих изображение.
- Признаки считаются независимыми друг от друга.
- Проведение стегоанализа:
  - $P(A_1|x_1, x_2, \dots, x_k) = \frac{P(x_1, x_2, \dots, x_k|A_1)P(A_1)}{P(x_1, x_2, \dots, x_k)}$ , где  $P(x_1, x_2, \dots, x_k|A_1) = \prod_{i=1}^k P(x_i | A_1)$
  - $P(A_2|x_1, x_2, \dots, x_k) = \frac{P(x_1, x_2, \dots, x_k|A_2)P(A_2)}{P(x_1, x_2, \dots, x_k)}$ , где  $P(x_1, x_2, \dots, x_k|A_2) = \prod_{i=1}^k P(x_i | A_2)$
- Принятие решения:
  - Если  $P(x_1, x_2, \dots, x_k|A_2)P(A_2) > P(x_1, x_2, \dots, x_k|A_1)P(A_1)$ , то стегоизображение.



## Закон Бенфорда

- Для реальных величин вероятность того, что цифра будет стоять на первом месте в числе тем выше, чем меньше эта цифра.
- Вероятность того, что  $x$  будет первой цифрой числа, вычисляется по формуле

$$P(x) = \log_{10} \left( 1 + \frac{1}{x} \right), \quad x = 1, \dots, 9$$


- Закон Бенфорда является простым, но эффективным инструментом стегоанализа.



## Статистические методы с автоматическим выбором признаков на основе машинного обучения


## Нейронные сети

- Нейронные сети – это адаптивные структуры, состоящие из множества параллельно действующих элементов
- Базовая структура нейронной сети состоит из нейронов, весов и активационного элемента, ответственного за принятие решения. Группы нейронов образуют слои
- Нейронную сеть, состоящую из множества слоев, называют глубинной



## Нейронные сети


- Глубинные нейронные сети используются для разделения изображения на два класса:
  - обычные изображения;
  - стегоизображения.
- Для использования этого метода необходимо накопить достаточно обширную базу стегоизображений



## Методы стеганографического встраивания

Одними из наиболее сложных для стегоанализа считаются следующие адаптивные методы:


- **HUGO** (Highly Undetectable Steganography) предназначен для пространственного домена. Основан на синдромном решетчатом кодировании (syndrome-trellis codes). Ключевая идея – минимизация вносимых изменений путем эффективного кодирования.
- **WOW** (Wavelet Obtained Weights) – встраивание осуществляется в пространственном домене в шумные и заполненные текстурами части изображения, определяемые с помощью вейвлет-преобразования.
- **S-UNIWARD** (UNiversal WAVElet Relative Distortion) является упрощенным вариантом WOW.



Выбор регионов для встраивания (по порядку): исходное изображение, HUGO, WOW, S-UNIWARD


## Пример (GNCNN)

- Обучение методом обратного распространения ошибки на базах BOSSBase и ImageNet со встраиванием методами HUGO, WOW и S-UNIWARD.
- Результат: ошибка 33,6% для изображений с 40% заполнением из ImageNet.
- Архитектура:



## Пример (TLU-CNN)

- Обучение на базах BOSSBase и BOWS2.
- Результат: ошибка 24% для изображений с 40% заполнением S-UNIWARD.
- Архитектура:



## Пример (PNet)

- Обучение на базах BOSSBase со встраиванием методами J-UNIWARD и UED.
- Результат: ошибка 7% для изображений с J-UNIWARD при обучении с J-UNIWARD, 27% без него.

M. Chen, V. Sedighi, M. Boroumand, and J. Fridrich. JPEG-phase-aware convolutional neural network for steganalysis of JPEG images. In M. Stamm, M. Kirchner, and S. Voloshynovskiy, editors, The 5th ACM Workshop on Information Hiding and Multimedia Security, Philadelphia, PA, June 20–22, 2017.

